Estística Descritiva

Max Pereira 24/04/2020

O objetivo é sintetizar os dados de maneira direta, preocupando-se menos com variações e intervalos de confiança dos dados.

Análise Exploratória

Conjunto de Dados (Dataset Iris)

```
dados <- iris
head(dados)</pre>
```

##		Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
##	1	5.1	3.5	1.4	0.2	setosa
##	2	4.9	3.0	1.4	0.2	setosa
##	3	4.7	3.2	1.3	0.2	setosa
##	4	4.6	3.1	1.5	0.2	setosa
##	5	5.0	3.6	1.4	0.2	setosa
##	6	5.4	3.9	1.7	0.4	setosa

Funções para efetuar estatística descritiva

- média: mean()
- desvio padrão: sd()
- variância: var()
- valor mínimo: min()
- valor máximo: max()
- mediana: median()
- amplitude de valores (min e máximo): range()
- quartis: quantile()
- função genérica: summary()

Medidas de tendência central

```
mean(dados$Sepal.Length)

## [1] 5.843333

median(dados$Sepal.Length)
```

Medidas de variabilidade

```
min(dados$Sepal.Length)
## [1] 4.3
max(dados$Sepal.Length)
## [1] 7.9
range(dados$Sepal.Length)
## [1] 4.3 7.9
quantile(dados$Sepal.Length)
## 0% 25% 50% 75% 100%
## 4.3 5.1 5.8 6.4 7.9
var(dados$Sepal.Length)
## [1] 0.6856935
sd(dados$Sepal.Length)
## [1] 0.8280661
```

Resumo estatístico

```
summary(dados)
```

```
##
    Sepal.Length
                   Sepal.Width
                                  Petal.Length
                                                 Petal.Width
## Min.
         :4.300
                  Min.
                         :2.000
                                 Min.
                                       :1.000
                                                Min.
                                                      :0.100
                  1st Qu.:2.800
## 1st Qu.:5.100
                                 1st Qu.:1.600
                                                1st Qu.:0.300
## Median :5.800 Median :3.000
                                 Median :4.350
                                                Median :1.300
## Mean
         :5.843
                  Mean :3.057
                                 Mean :3.758
                                                      :1.199
                                                Mean
##
   3rd Qu.:6.400
                  3rd Qu.:3.300
                                 3rd Qu.:5.100
                                                3rd Qu.:1.800
                 Max. :4.400
                                 Max. :6.900
## Max.
        :7.900
                                                Max. :2.500
##
         Species
##
   setosa
             :50
## versicolor:50
##
   virginica:50
##
##
##
```

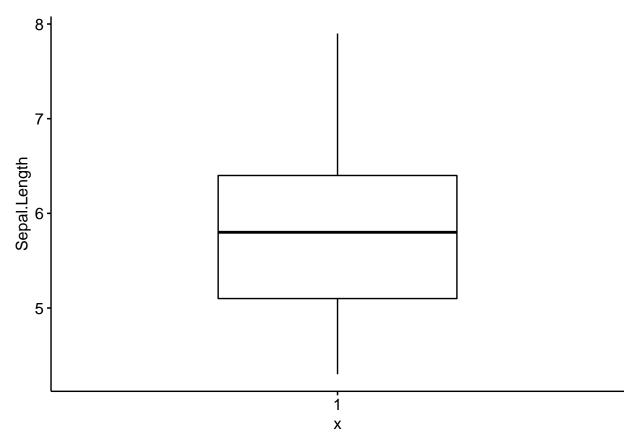
Gráficos de distribuições

library(ggpubr)

```
## Loading required package: ggplot2
## Loading required package: magrittr
```

Box plot

```
ggboxplot(dados, y="Sepal.Length", width = 0.5)
```



Analisando o boxplot (outliers)

```
v = c(10.2, 14.1, 14.4, 14.4, 14.4, 14.5, 14.5, 14.6, 14.7, 14.7, 14.7, 14.9, 15.1, 15.9, 16.4)
v
```

[1] 10.2 14.1 14.4 14.4 14.4 14.5 14.5 14.6 14.7 14.7 14.7 14.9 15.1 15.9 ## [15] 16.4

summary(v)

```
## Min. 1st Qu. Median Mean 3rd Qu. Max.
## 10.2 14.4 14.6 14.5 14.8 16.4
```

IQR(v) # Interquartile range

[1] 0.4

Se um valor estiver abaixo de Q1-1.5xIQR ou acima de Q3+1.5xIQR é considerado um outlier

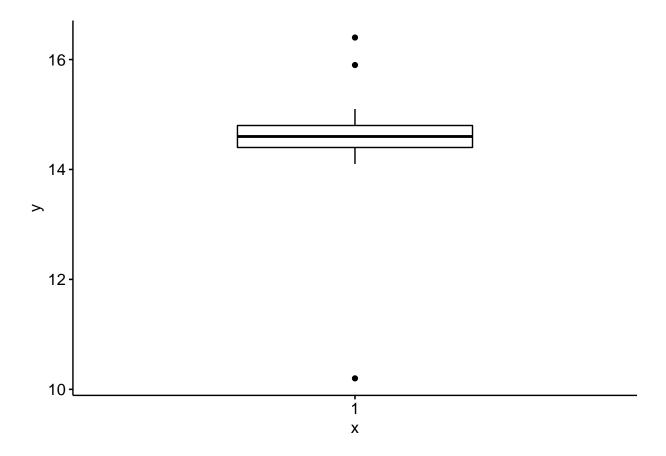
```
q1 = summary(v)[2]
q3 = summary(v)[5]
limite_inferior = q1-1.5*IQR(v)
limite_inferior

## 1st Qu.
## 13.8

limite_superior = q3+1.5*IQR(v)
limite_superior

## 3rd Qu.
## 15.4
```





Histograma

```
gghistogram(dados, x = "Sepal.Length", bins = 9, add = "mean")
```

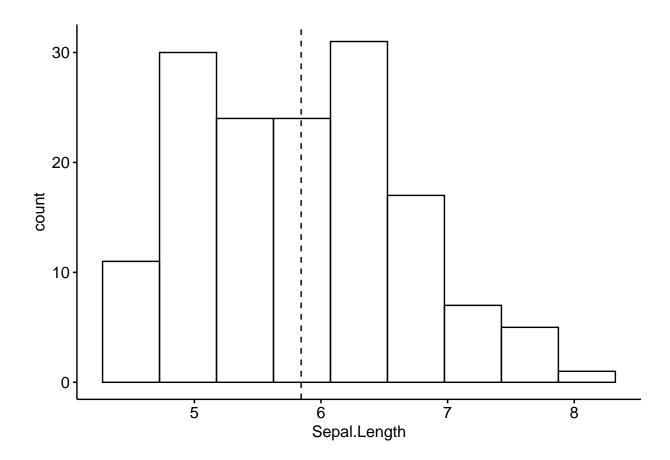
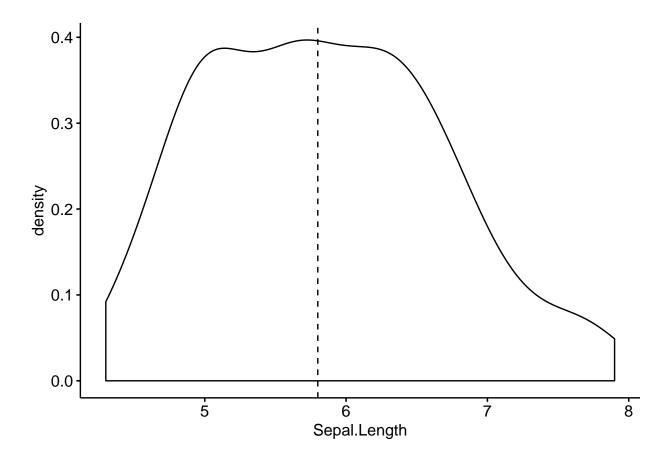


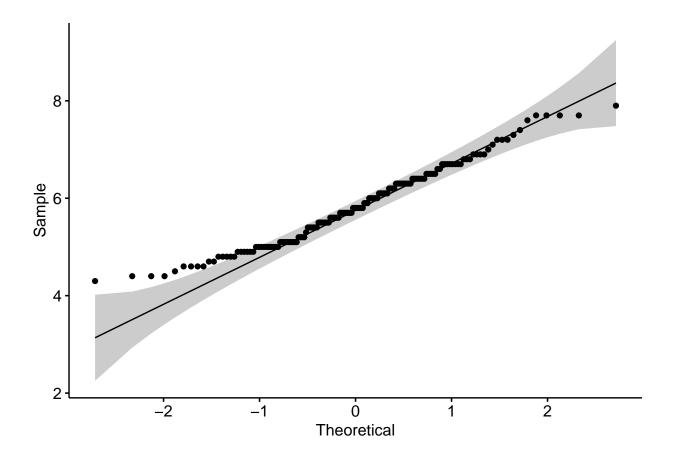
Gráfico de densidade

```
ggdensity(dados, x = "Sepal.Length", add = "median")
```



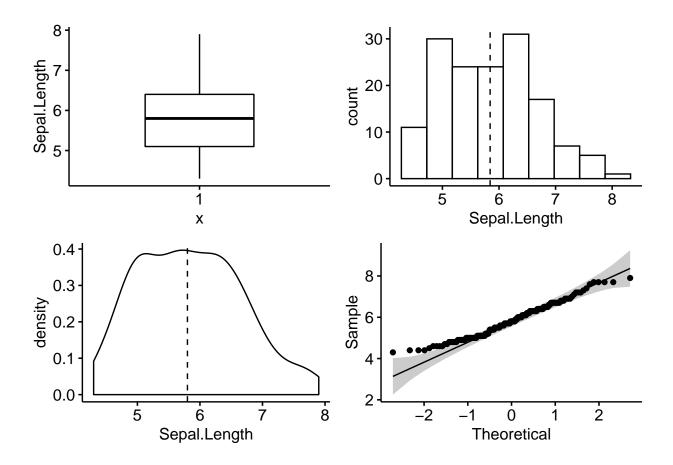
${\bf A}{\bf n}{\acute{\bf a}}{\bf l}{\bf i}{\bf s}{\bf e}~{\bf d}{\bf e}~{\bf d}{\bf i}{\bf s}{\bf t}{\bf r}{\bf i}{\bf b}{\bf u}{\bf i}{\bf c}{\~a}{\bf o}~{\bf n}{\bf o}{\bf r}{\bf m}{\bf a}{\bf l}$

```
ggqqplot(dados, x="Sepal.Length")
```



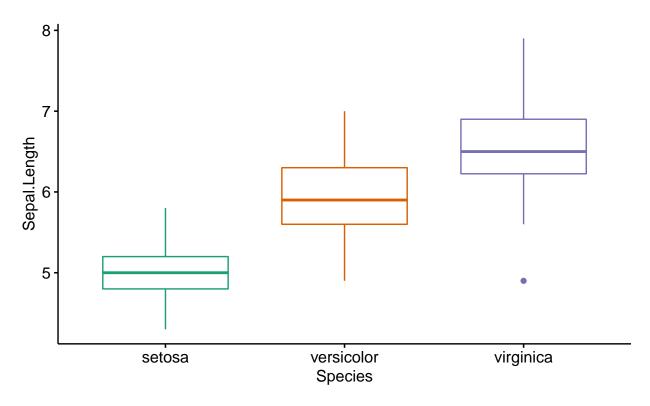
Combinando os gráficos na mesma área de plotagem

```
bp <- ggboxplot(dados, y="Sepal.Length", width = 0.5)
ht <- gghistogram(dados, x = "Sepal.Length", bins = 9, add = "mean")
ds <- ggdensity(dados, x = "Sepal.Length", add = "median")
dn <- ggqqplot(dados, x="Sepal.Length")
ggarrange(bp, ht, ds, dn)</pre>
```



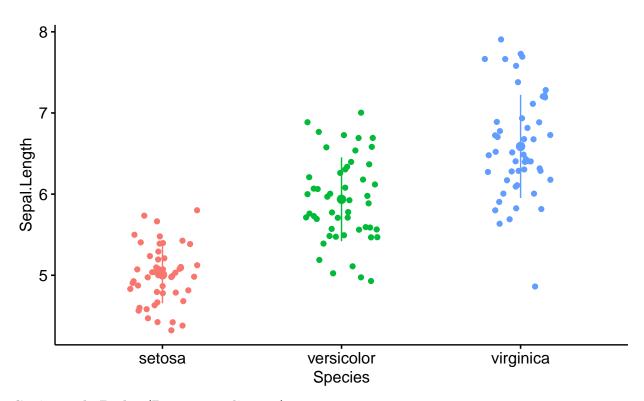
Gráficos para dados agrupados





Os valores permitidos para o parâmetro palette são: "grey" para paleta de cores cinzas; paletas de cores "brewer": "RdBu", "Blues", "Dark2"; Para ver todas: RColorBrewer::display.brewer.all(); paletas customizadas: c("blue", "red"); paletas de jornais científicos do pacote "ggsci": "npg", "aaas", "lancet", "jco", "ucscgb", "uchicago", "simpsons" and "rickandmorty".





Conjunto de Dados (Dataset credito.csv)

```
df <- read.csv("credito.csv")
str(df)</pre>
```

```
'data.frame':
                    114 obs. of
                                12 variables:
##
                    : Factor w/ 87 levels "004NZMX60E","017STAOLDV",..: 1 1 2 3 4 5 6 6 6 7 ...
##
   $ Id
                    : Factor w/ 34 levels "AK", "AL", "AR", ...: 4 4 23 23 7 22 23 23 26 ...
##
   $ estado
##
   $ sexo
                    : Factor w/ 2 levels "Female", "Male": 2 2 1 2 2 2 1 1 1 2 ...
                    : int 36 36 34 48 32 44 60 60 60 48 ...
##
   $ idade
                    : Factor w/7 levels "American Indian or Alaska Native",..: 5 5 7 5 7 6 2 2 2 1 ...
##
   $ raca
   \ estado_civil : Factor w/ 3 levels "Divorced", "Married",...: 2 2 2 2 3 3 3 3 2 ...
##
                    : Factor w/ 5 levels "Accout", "Business", ...: 5 5 3 1 2 1 4 4 4 1 ...
   $ ocupacao
##
   $ score_credito : int
                          710 720 720 670 720 540 840 824 824 490 ...
                           9371 9371 9010 6538 8679 ...
##
   $ rendimento
                    : num
                           2000 3014 1000 2099 1000 ...
##
   $ debitos
                    : Factor w/ 4 levels "Auto", "Credit", ...: 4 1 2 3 3 4 4 1 2 4 ...
##
   $ tipo_financ
   $ decisao_financ: Factor w/ 3 levels "Approved", "Denied", ...: 1 1 1 1 1 2 1 1 1 2 ...
```

Tabelas de frequência

Usada para descrever variáveis categóricas. Contém as contagens de cada combinação dos níveis dos fatores.

```
tipo.financiamento <- df$tipo_financ
ocupacao <- df$ocupacao
parecer <- df$decisao_financ</pre>
```

Distribuição de frequência:

```
table(tipo.financiamento)
## tipo.financiamento
       Auto Credit
                       Home Personal
##
        40
                 17
                           23
table(ocupacao)
## ocupacao
   Accout Business
                           IT Manager
                                           NYPD
                                    26
##
        18
               15
                           27
                                             28
table(parecer)
## parecer
                Denied Withdrawn
## Approved
         70
                    32
                              12
Convertendo as tabelas para dataframes
df_fin <- as.data.frame(table(tipo.financiamento))</pre>
df_oc <- as.data.frame(table(ocupacao))</pre>
df_par <- as.data.frame(table(parecer))</pre>
```

Gráfico de barras

```
fin <- ggbarplot(df_fin, x="tipo.financiamento", y="Freq")
oc <- ggbarplot(df_oc, x="ocupacao", y="Freq")
par <- ggbarplot(df_par, x="parecer", y="Freq")
ggarrange(fin, oc, par)</pre>
```

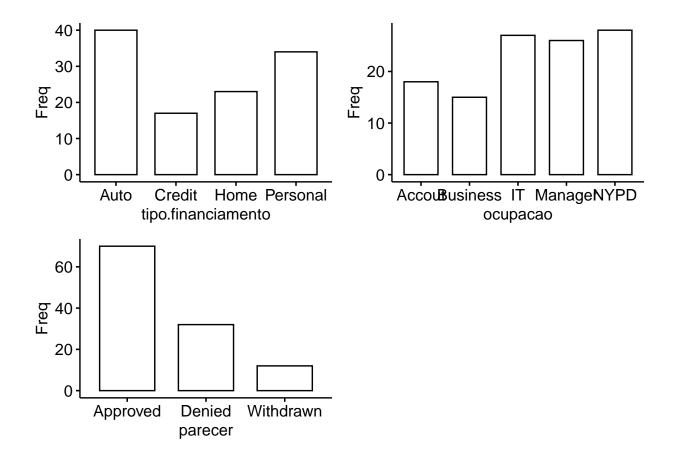


Gráfico de pizza

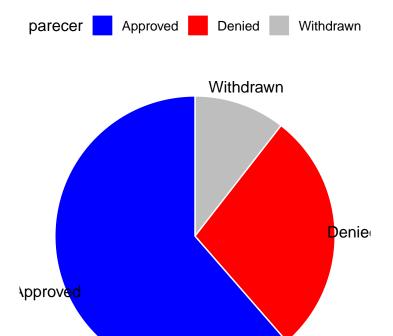
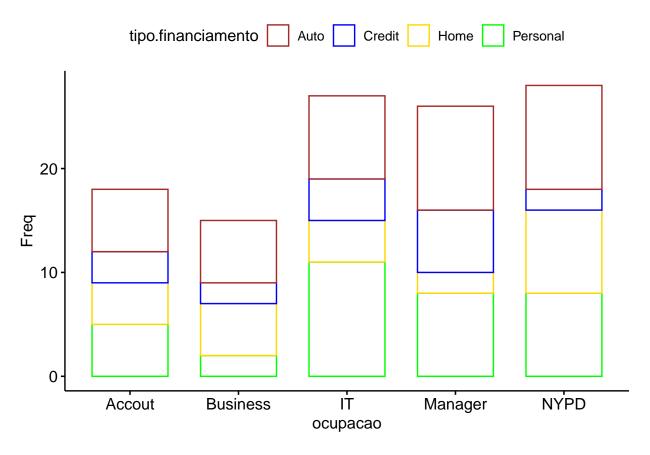
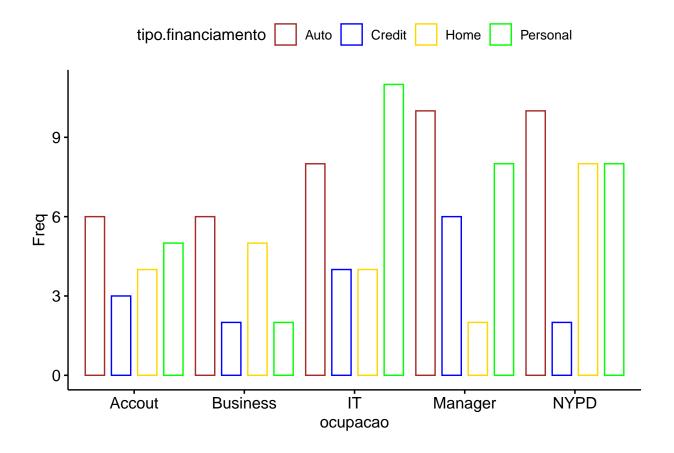


Tabela com duas variáveis categóricas

```
tbl2 <- table(tipo.financiamento, ocupacao)</pre>
tbl2
##
                  ocupacao
## tipo.financiamento Accout Business IT Manager NYPD
##
           Auto
                   6 6 8
                                              10
##
           Credit
                        3
                                2 4
                                         6
                                              2
           Home
                              5 4
##
                      4
                                              8
                      5
                                2 11
##
           Personal
                                          8
                                              8
```

Transformando a tabela em um dataframe para visualizar o gráfico de barras





Frequência relativa com a função prop.table()

Segundo parâmetro: 1 para linhas e 2 para colunas

```
prop.table(tbl2, 1)
##
                     ocupacao
##
  tipo.financiamento
                           Accout
                                    Business
                                                      ΙT
                                                            Manager
                                                                           NYPD
##
             Auto
                      0.15000000 0.15000000 0.20000000 0.25000000 0.25000000
##
             Credit
                       0.17647059 0.11764706 0.23529412 0.35294118 0.11764706
                       0.17391304 0.21739130 0.17391304 0.08695652 0.34782609
##
             Home
##
             Personal 0.14705882 0.05882353 0.32352941 0.23529412 0.23529412
prop.table(tbl2, 2)
##
                     ocupacao
```

```
## tipo.financiamento
                       Business
                                  IT
                                      Manager
                                                NYPD
                 Accout
##
        Auto
              ##
        Credit
              0.16666667 0.13333333 0.14814815 0.23076923 0.07142857
              ##
        Home
##
        Personal 0.27777778 0.13333333 0.40740741 0.30769231 0.28571429
```

Percentuais

round(prop.table(tbl2, 1), 2)*100

##	ocupacao								
##	tipo.financiamento	${\tt Accout}$	${\tt Business}$	IT	Manager	NYPD			
##	Auto	15	15	20	25	25			
##	Credit	18	12	24	35	12			
##	Home	17	22	17	9	35			
##	Personal	15	6	32	24	24			